

Отчет о проведенной НИРС

Разделы

| | | |
|----------|---|----------|
| 1 | Существующие подходы определения и классификации автомобилей | 2 |
| 1.1 | Использование трехмерной структуры и нейросети | 2 |
| 1.2 | Deep Belief Network | 2 |
| 1.3 | Использование цепочки классификаторов | 3 |
| 1.4 | Байесовские сети | 3 |
| 1.5 | Car-Rec | 4 |
| 2 | Классификация без явного определения признаков | 4 |
| 2.1 | Сверточные нейронные сети | 5 |
| 2.2 | Глубокие сверточные нейронные сети | 5 |
| 2.3 | Плиточные сверточные нейронные сети | 6 |
| 3 | Обучение нейросетей | 6 |
| 3.1 | Эффективное обратное распространение ошибки | 6 |
| 3.2 | Использование графического процессора | 6 |
| 3.3 | Дообучение сети | 7 |

1 Существующие подходы определения и классификации автомобилей

1.1 Использование трехмерной структуры и нейросети [1]

Данный метод основан на представлении автомобилей в виде полигональной модели, по которой происходит выделение признаков, передаваемых на вход нейросети. Трехмерная структура описания автомобиля разделена на восемь частей, в каждой из которых выделяется опорная вершина. В качестве признаков используется расстояние между каждой парой опорных вершин. Дополнительно рассматриваются параметры колес автомобиля, их радиус и положение.

Авторы работ использовали трехслойную, полносвязную нейронную сеть с 30 входами (количество признаков) и 120 выходами (6×20 , 6 — количество классов, 20 — число выходных нейронов для каждого класса). Результат определялся поиском максимального значения в выходном слое.

При обучении сети использовался метод обратного распространения ошибки. В качестве ошибочной, для улучшения сходимости, использовалась экспоненциальная функция вместо квадратичной.

Обучающая выборка состояла из 500 изображений с дорожных камер. Классификация производилась на большие/небольшие грузовики и автомобили. Тестовая выборка включала в себя еще 300 изображений, из которых правильно классифицировано 91%, ошибочно 4% и в 5% случаев система не смогла определить автомобиль на изображении.

1.2 Deep Belief Network [2]

Развитие идеи использования рекуррентных нейронных сетей, которые тяжело обучать из-за наличия обратных связей. Рассматривается архитектура при которой внутри скрытых слоев используется ограниченная машина Больцмана.

Авторы рассматривают задачу определения автомобиля по фотографии сзади (как с камеры авторегистратора). Входной слой имеет размерность соответствующую размерности изображения (признаки — пиксели). Выходов

два — классы автомобиль и не автомобиль.

Тестирование происходило на 735 изображениях, рассматривались модели с одним, двумя и тремя скрытыми слоями. Наилучшая точность была получена при использовании двух скрытых слоев — более 96%. Также была произведена оценка точности для других алгоритмов: искусственных и сверточных нейросетей, k ближайших соседей и метода опорных векторов. Среди них наибольшая точность результата получилась при использовании сверточных нейронных сетей, почти 95%.

1.3 Использование цепочки классификаторов

В работе [3] ставилась задача определения боковых стоек автомобиля. Решение задачи представляло собой многослойную схему классификации, от общего к частному. Такой подход называют усилением простых классификаторов (boosting classifier). Первые слои предназначены для обработки входного изображения, определения направления движения, колес, выделение боковой части автомобиля и только после этого поиск боковых стоек на основе гистограммы ориентированных градиентов и геометрических моделей.

Обучение системы производилось на изображениях автомобильного потока, в тестовую выборку также включены негативные примеры не содержащие транспортных средств. Тренировочное множество состоит из 100000 изображений без автомобилей и 4000 с автомобилями. Тестовая выборка содержит 1000 положительных и 200000 негативных примеров. Итоговая точность 90% для положительных примеров и 99% для негативных.

1.4 Байесовские сети

Имея возможность выделения признаков для дальнейшего решения задачи классификации можно воспользоваться байесовской сетью. Такой подход использовался в работе выделения автомобилей на фотоаэроснимках низкого разрешения [4]. Основная проблема при решении этой задачи — высокое количество шумов: тени, солнечные блики, кроны деревьев и прочее.

Авторы предложили метод, основанный на использовании дополнительной известной информации о времени и месте съемки. Эти данные и вы-

деленные признаки объектов вместе попадают в байесовскую сеть, которая производит отсев таких неправильно определенных кандидатов как тени от настоящих автомобилей и объектов находящихся не на дорожном полотне.

1.5 Car-Rec [5]

Еще одно предложенное решение для задачи классификации автомобилей, заключающееся в выделении признаков и их обработке с использованием деревьев поиска по заготовленной базе. Для определения регионов интереса на изображении используется алгоритм SURF [6], основанный на интегральном представлении входной картинки. Разработанная система имеет точность более 90%.

2 Классификация без явного определения признаков

Практически все перечисленные выше подходы для решения задачи определения или классификации автомобилей занимались выделением опорных признаков по которым строился ответ. В пункте 1.1 использовалась заготовленная трехмерная модель, описывающая транспортное средство, а в 1.4 рассматривались физические известные факторы предметной области.

Однако, не всегда имеется возможность применить данный подход, так как в общем случае не понятно по какому принципу выбирать признаки для классификации. Кроме этого, не известно как с течением времени будет развиваться предметная область и какие еще признаки необходимо зарезервировать для дополнительных классов.

При использовании нейросетей, признаки для классификации автоматически вырабатываются при обучении модели. В случае необходимости добавить новые классы в классификатор, производят его переобучение, в результате чего выводятся новые признаки. Также возможно произвести более быструю настройку, скорректировав весовые коэффициенты без перестроения признаков (дообучение сети).

2.1 Сверточные нейронные сети

В работе [7] рассматривалась задача распознавания номерных табличек на домах. Использовалась традиционная архитектура сверточной нейросети: первый сверточный слой выделял 16 карт признаков со сверткой 5×5 , второй — 512, со сверткой 7×7 , два слоя классификации по 20 нейронов каждый. Применялся многоступенчатый подход выделения признаков (слоям классификации были доступны все предыдущие карты признаков). Описанная модель реализована на фреймворке EBLearn [8].

Был произведен подбор оптимального параметра степени свертки для алгоритма выделения признаков Lp-Pooling. Наилучшая точность получена при использовании коэффициента $p = 4$. Кроме этого, перед передачей изображения в сеть, вокруг него достраивалась рамка из двух пикселей с нулевым значением, чтобы отцентрировать первый этап свертки рамкой 5×5 на границе рассматриваемой картинки.

Набор данных состоял из трех частей: обучающей, тестовой и дополнительной выборках. Дополнительная выборка состояла из большого количества легких для классификации изображений, а обучающая содержала небольшое число более сложных примеров. Обучение происходило на 6000 примеров, выбранных случайным образом из обучающего множества ($2/3$) и из дополнительного ($1/3$). В результате, при тестировании была получена точность более 95%.

2.2 Глубокие сверточные нейронные сети

Один из вопросов систем распознавания и классификации изображений — на сколько большую предметную область можно охватить используя автоматические методы. В рамках состязания ILSVRC проводится попытка классифицировать огромный тестовый набор изображений (более миллиона) по тысяче категорий.

Авторы работы [9] занимались созданием одной из самых больших сверточных нейросетей для участия в ILSVRC-2012. Она состояла из 5 сверточных и 3 полносвязных слоев, включающих 60 миллионов параметров и 650 тысяч нейронов. В работе говорилось о необходимости и важности большой размерности сети, так как при попытке избавиться хотя бы от одного слоя

происходило сильное падение качества классификатора.

Для уменьшения вероятности переобучения использовался подход выбывающих нейронов [10]. В качестве активационной функции была выбрана модель параметрического выпрямляемого элемента ReLU [11]. При тестировании по мере оценки ошибки top-5 error была получена точность 84.7%.

На соревнованиях ILSVRC-2014 была представлена еще большая сеть, включающая 27 слоев [12]. Команде GoogLeNet получилось добиться результатов в 6.67% ошибок.

2.3 Плиточные сверточные нейронные сети

Сверточные нейронные сети хорошо применяются для задач классификации и распознавания объектов, однако подход использования разделяемых весов может помешать в процессе обучения выделить некоторые инвариантные признаки. В работе [13] предлагался метод при котором разделяемые веса чередовались с некоторым шагом k . Так при $k = 1$ получалась обычная сверточная нейронная сеть, а при увеличении этого параметра строилась очередная модель, которая является компромиссом между способностью выявления инвариантностей изображения и сложностью обучения системы.

Тестирование производилось на наборе данных CIFAR-10, состоящем из 50000 обучающих изображений и 10000 тестовых, которые необходимо классифицировать по 10 категориям. Полученная точность метода более 73%.

3 Обучение нейросетей

3.1 Эффективное обратное распространение ошибки

3.2 Использование графического процессора

3.3 Дообучение сети

Список литературы

- [1] *Wu, W.* A method of vehicle classification using models and neural networks / W. Wu, Z. QiSen, W. Mingjun // Vehicular Technology Conference, 2001. VTC 2001 Spring. IEEE VTS 53rd / IEEE. — Vol. 4. — 2001. — Pp. 3022–3026.
- [2] *Wang, H.* A vehicle detection algorithm based on deep belief network / H. Wang, Y. Cai, L. Chen // *The scientific world journal*. — 2014. — Vol. 2014.
- [3] *Brehar, R.* Pillars detection for side viewed vehicles / R. Brehar, S. Nedevschi, L. Dăian // Intelligent Computer Communication and Processing (ICCP), 2010 IEEE International Conference on / IEEE. — 2010. — Pp. 247–250.
- [4] *Zhao, T.* Car detection in low resolution aerial images / T. Zhao, R. Nevatia // *Image and Vision Computing*. — 2003. — Vol. 21, no. 8. — Pp. 693–703.
- [5] *Jang, D. M.* Car-rec: A real time car recognition system / D. M. Jang, M. Turk // applications of computer vision (WACV), 2011 IEEE Workshop on / IEEE. — 2011. — Pp. 599–605.
- [6] Speeded-up robust features (surf) / H. Bay, A. Ess, T. Tuytelaars, L. Van Gool // *Computer vision and image understanding*. — 2008. — Vol. 110, no. 3. — Pp. 346–359.
- [7] *Sermanet, P.* Convolutional neural networks applied to house numbers digit classification / P. Sermanet, S. Chintala, Y. LeCun // Pattern Recognition (ICPR), 2012 21st International Conference on / IEEE. — 2012. — Pp. 3288–3291.
- [8] *Sermanet, P.* Eblearn: Open-source energy-based learning in c++ / P. Sermanet, K. Kavukcuoglu, Y. LeCun // Tools with Artificial Intelligence, 2009. ICTAI'09. 21st International Conference on / IEEE. — 2009. — Pp. 693–697.

- [9] *Krizhevsky, A.* Imagenet classification with deep convolutional neural networks / A. Krizhevsky, I. Sutskever, G. E. Hinton // Advances in neural information processing systems. — 2012. — Pp. 1097–1105.
- [10] Dropout: A simple way to prevent neural networks from overfitting / N. Srivastava, G. Hinton, A. Krizhevsky et al. // *The Journal of Machine Learning Research*. — 2014. — Vol. 15, no. 1. — Pp. 1929–1958.
- [11] *Dahl, G. E.* Improving deep neural networks for lvcsr using rectified linear units and dropout / G. E. Dahl, T. N. Sainath, G. E. Hinton // Acoustics, Speech and Signal Processing (ICASSP), 2013 IEEE International Conference on / IEEE. — 2013. — Pp. 8609–8613.
- [12] Going deeper with convolutions / C. Szegedy, W. Liu, Y. Jia et al. // *arXiv preprint arXiv:1409.4842*. — 2014.
- [13] Tiled convolutional neural networks / J. Ngiam, Z. Chen, D. Chia et al. // Advances in Neural Information Processing Systems. — 2010. — Pp. 1279–1287.